Google Cloud

GOOGLE CLOUD SECURITY ARCHITECTURE

Model Armor API 与 Gemini 4

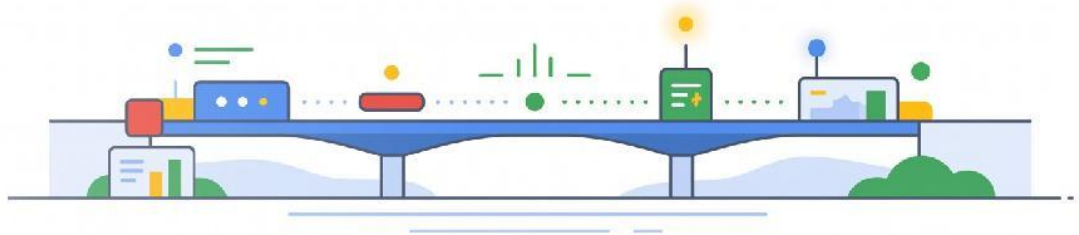


多模态内容审核、落地页治理与跨区域合规架构

Google Cloud 团队 · 2026 年 10 月

EXECUTIVE SUMMARY

双层安全架构兼顾 秒级拦截 与 合规审计



基于文本、图片与伪装落地页的实测结论

100 ms

文本端到端实测延迟

含网络开销（实测基准）

700 ms

多模态图片实测延迟

OCR + 视觉分类并行（实测）

4 MiB

单图最大处理上限

配合前置标准化防静默放行

01 **业务挑战与双层纵深架构**

剖析终端越狱、伪装落地页挑战与双层协同机制

02 **多模态图片审核与防静默放行**

详解 OCR 坐标框、视觉分类、Gemini 4 复核与避坑

03 **广告落地页三段式治理流水线**

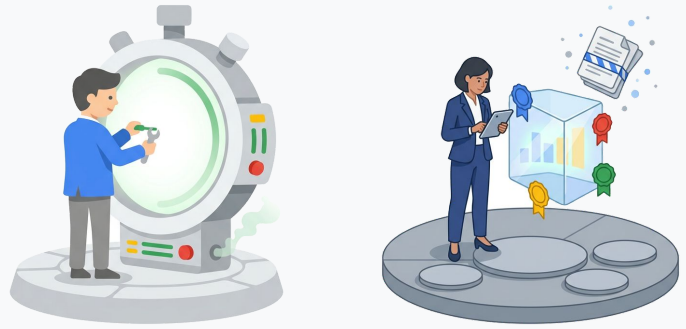
Safe Browsing 结合无头浏览器正文及截图双重审查

04 **跨区域合规词库与实施路线图**

SDP 正则脱敏、成本权衡矩阵

核心架构主张

高速拦截越狱、恶意链与敏感词



SECURITY CHALLENGES

智能终端与全球生态面临三大内容安全挑战

单一词库或纯模型难以兼顾延迟与召回率

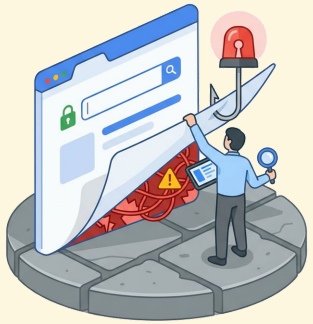
挑战一：终端图文夹带越狱

- 越狱指令嵌入海报绕过纯文本网关
- 语音与视觉助手面临跨模态注入
- 缺文字坐标框难以支撑精准打码



挑战二：落地页视觉伪装

- 网页正文干净但将违规词绘入海报
- 钓鱼链接隐藏在动态脚本或二维码
- WebP 与超大图默认易触发静默放行



挑战三：跨区域合规差异

- 全球通用基线不含特定区域政企词库
- 传统词典分词在连续中文下易漏报
- 隐喻与艺术画作易造成误报或漏报



核心症结 — 确定性规则缺乏上下文理解，而全量调用大模型推理成本高且缺乏统一脱敏基线。

REFERENCE ARCHITECTURE

Model Armor 与 Gemini 4 纵深防御

首层拦截约 85% 违规（预估），边缘转二层

接入与预处理

- **终端网关** — 图像转码
- **Cloud Run** — 动态抓取
- **API 网关** — 状态校验

Model Armor

- **RAI 防越狱** — 多模态过滤
- **Safe Browsing** — 恶意链拦截
- **SDP 保护** — 正则与脱敏

Gemini 4 复核

- **视觉复核** — 艺术品甄别
- **合规裁判** — 隐喻转 JSON
- **BigQuery** — 审计日志库

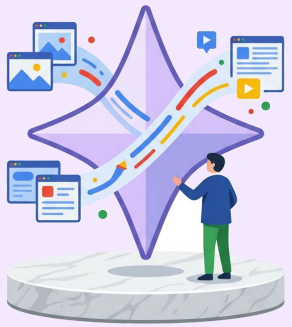
第一层防线

高速基线过滤与脱敏



第二层防线

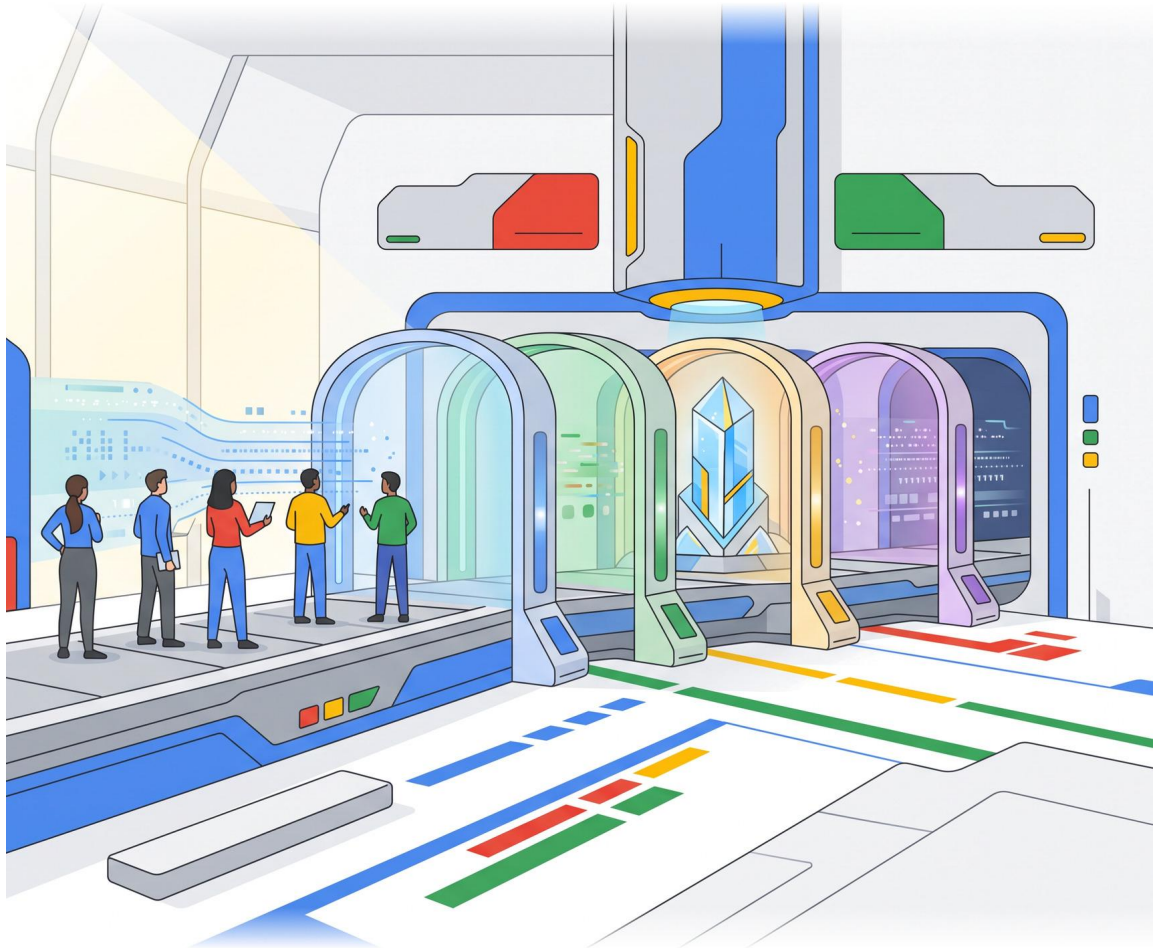
Gemini 4 推理出 JSON



LAYER 1 · MODEL ARMOR API

Model Armor API 提供统一安全网关

单次调用并行执行五大过滤器与敏感数据保护



全面覆盖输入清洗与输出审计

- 提供 sanitizeUserPrompt 与 sanitizeModelResponse 接口
- 与底层大模型解耦，统一保护自研与第三方模型

五大内置安全检测器并行执行

- 涵盖 RAI 有害内容、提示词越狱与 CSAM 拦截
- 集成 Safe Browsing 实时识别钓鱼与恶意软件链接

深度集成高级敏感数据保护 (SDP)

- 挂载自定义正则 Inspect 与自动脱敏 De-id 模板
- 支持多语言检测与 Floor Settings 全局基线管控

MULTIMODAL IMAGE AUDIT

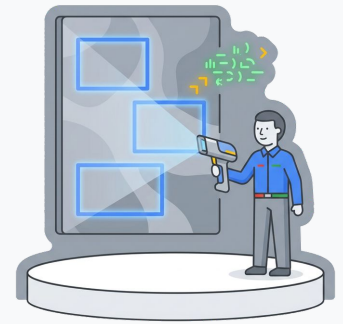
图片审核实现 OCR 与视觉 双路径

实测：图片模态仅支持 us/eu/global 端点

检测维度	技术实现机制	返回结果粒度	适用风险场景与实测表现
区域与模态配置	仅支持 us / eu / global 端点，声明 MODALITY_IMAGE	API 路由校验	us-central1 建图片模板返 400；发纯文本模板返 FAILURE
路径 ①：OCR 路径	提取图中文字送入 RAI、越狱、URL 与 SDP 正则	字符级 + 像素坐标框	拦截海报隐藏越狱指令、PII 与敏感词，坐标框用于打码
路径 ②：视觉路径	高级 SDP 挂载 IMAGE_TYPE/CONTEXT/* 视觉类别	整图分类 + 似然度	覆盖无文字图片；VERY_LIKELY 拦截，POSSIBLE 转 Gemini 4
二维码与长链接	OCR 对长 URL 易产生空格切分（如 testsafe browsing）	应用侧独立解析	生产流水线额外提取二维码与 URL 作为纯文本单独送审

OCR 坐标框

返回违规字像素边界框



多区域路由

绑定 us/eu/global 端点

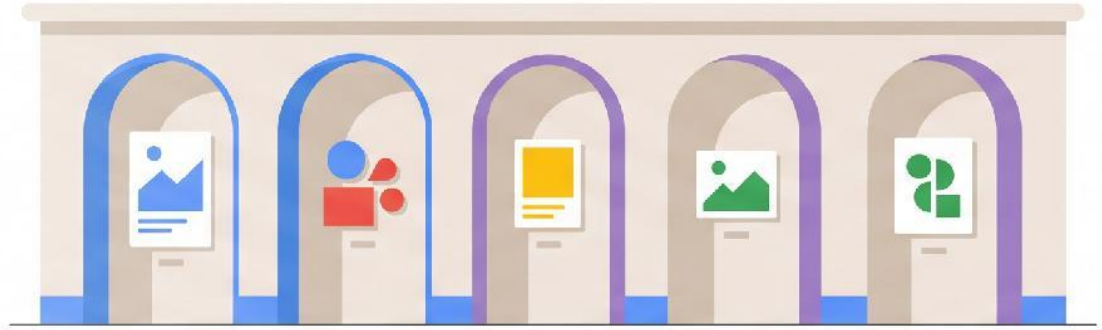


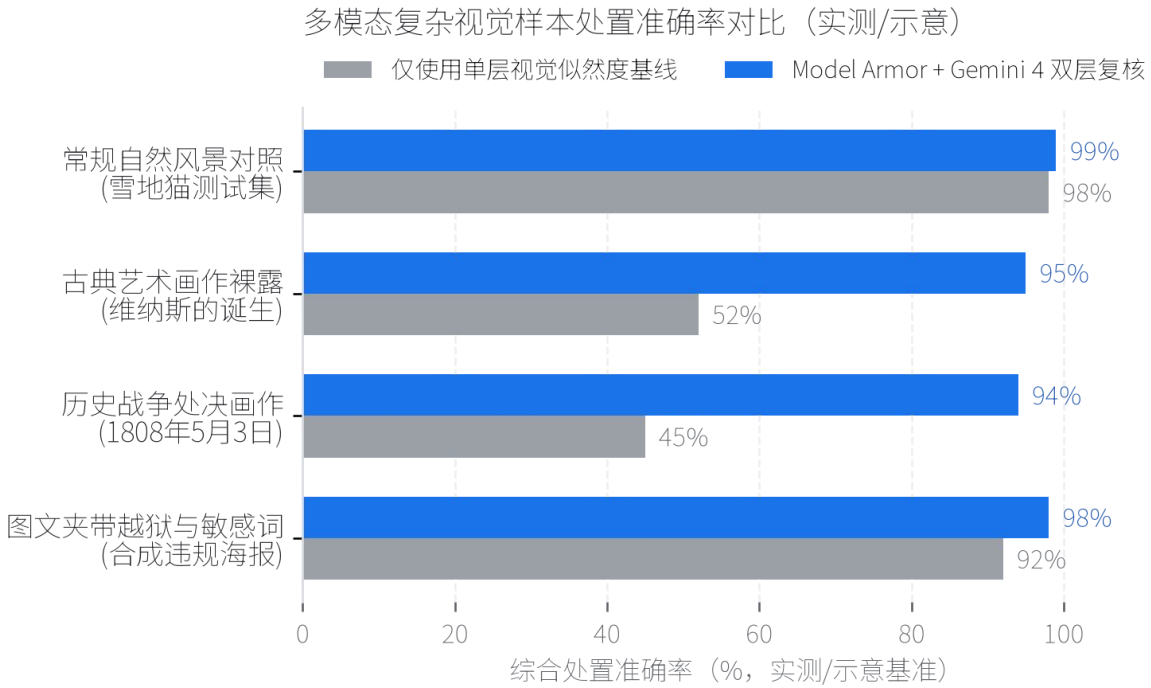
表格阅读要点 — 无文字图片须配置 SDP 视觉 InfoType；图片模板仅挂 Inspect 模板以防跳过。

LAYER 2 · GEMINI 4 VISUAL JUDGE

引入 Gemini 4 视觉复核降低艺术画作误判

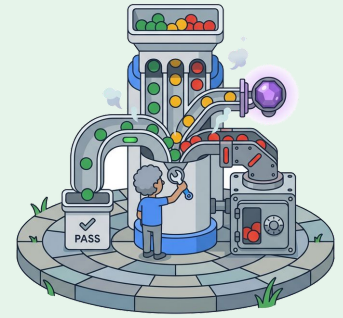
实测对比：弥补分类器对艺术画作的语境盲区





正向收益驱动 (Growth Drivers)

- 区分古典艺术名画与真实违规色情
- 识别战争画作暴力信号并输出理由



关键风险管控 (Key Risks & Asks)

- 最低返回阈值设为 POSSIBLE 防误报
- 固定 temperature=0 配合人工抽检



分级处置策略 — LIKELY 及以上由 Model Armor 直接拦截；POSSIBLE 触发 Gemini 4 复核并输出 JSON。

PRODUCTION ENGINEERING GUARDRAILS

前置图像转码与校验消除静默放行 隐患

实测：WebP 与超 4 MiB 图片返 200 但跳过过滤

步骤 1：前置图像转码与 4 MiB 限流

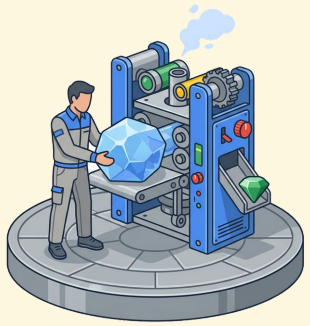
```python
def normalize_image(raw: bytes, max_side=2000) -> bytes:
    im = Image.open(io.BytesIO(raw)).convert("RGB")
    return encode_jpeg_under_4mib(im, max_side)
```

步骤 2：Fail-Closed 状态机严格校验

```python
def is_trustworthy(sr: dict) -> bool:
    ok = sr.get("invocationResult") == "SUCCESS"
    return ok and not has_skipped_filters(sr)
```

陷阱一：WebP 格式跳过

原样送审返 FAILURE，须前置统一转 JPEG。



陷阱二：超 4 MiB 静默跳过

超限长截图过滤器 SKIPPED，须压缩校验。



工程铁律 — 不可仅凭 HTTP 200 放行，须断言 is_trustworthy(sr) 为真。

LANDING PAGE COMPLIANCE PIPELINE

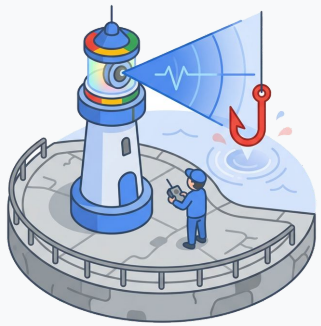
三段式流水线精准拦截图文伪装落地页

应对文本干净、将违规标语绘入首屏海报手法

阶段 ①：URL 威胁检测	阶段 ②：动态抓取正文	阶段 ③：首屏截图复核
Safe Browsing 拦截钓鱼链接	无头浏览器提取正文与跳转链	**转码后执行 OCR 与视觉审计**

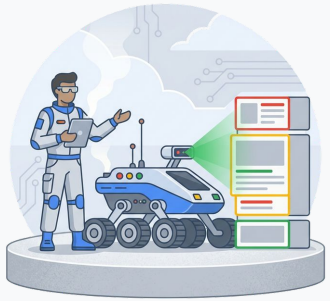
① URL 级威胁检测

- 毫秒级识别钓鱼与木马
- 不主动抓取网页正文



② 反 Cloaking 抓取

- Cloud Run 渲染真实 DOM
- 解析二维码与短链送审



③ 首屏海报图文穿透

- 拦截正文干净的违规海报
- 捕获伪造公文与违规邮箱

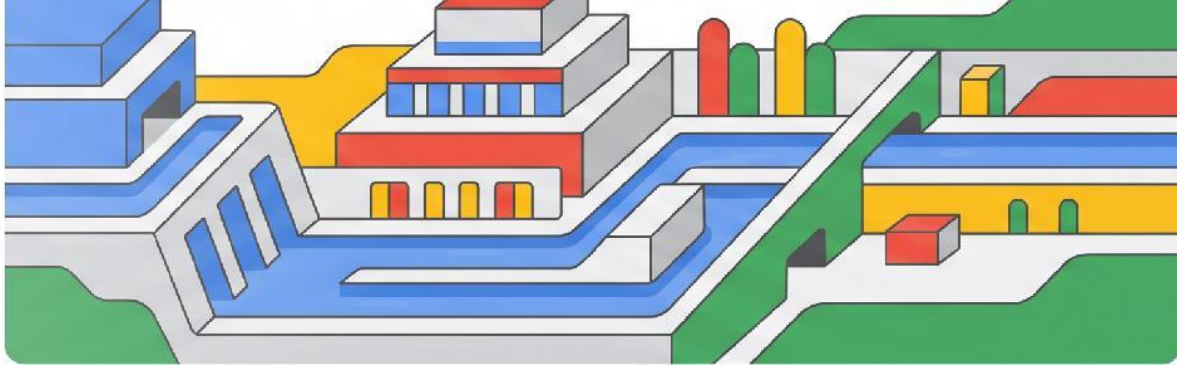


落地页治理结论 — 任一阶段命中或过滤器跳过均触发 BLOCK / REVIEW，封堵图文分离黑产页。

LOCALIZED COMPLIANCE & DLP

采用 SDP 正则表达式 实现中文敏感词全召回

全球安全基线叠加自定义策略与自动脱敏



传统误区 • DICTIONARY

词典模式（中文易漏报）

按空格或标点词边界分词匹配

连续中文句子无分隔符时漏报

图片混挂脱敏模板导致被跳过

VS

推荐方案 • REGEX + DE-ID

正则模式（全量召回）

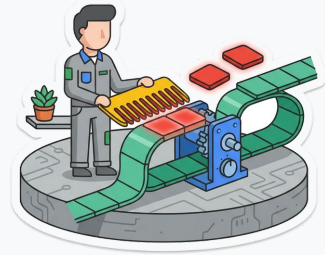
自定义 Regex 突破中文分词限制

实测连续中文敏感词 100% 召回

文本挂 De-id 自动替换占位符

中文正则命中

按主题拆分多个词库



实时隐私脱敏

送模型前掩码敏感词



对外产品定位 — 内置 RAI 提供全球通用安全基线；区域政企合规通过 SDP 自定义正则与 Gemini 4 落地。

GEMINI 4 NEXT-GEN CAPABILITIES

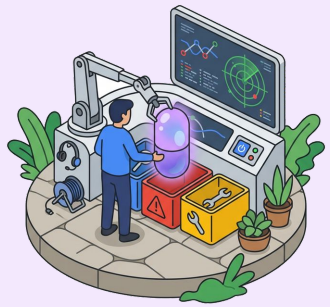
Gemini 4 多模态推理精准识别隐喻与变体

输出结构化 JSON 判罚依据对接安全运营中心



语义裁判三大核心价值

- **隐喻识别**：拦截无敏感词的诱导与集会文案
- **结构化输出**：返回风险等级与中文判罚理由
- **注入调优**：中文设 MEDIUM_AND_ABOVE 降误报



双层联动闭锁 — 只要 Model Armor 命中恶意链接/正则或 Gemini 4 判定 BLOCK，网关即刻执行阻断。

ARCHITECTURAL TRADE-OFFS

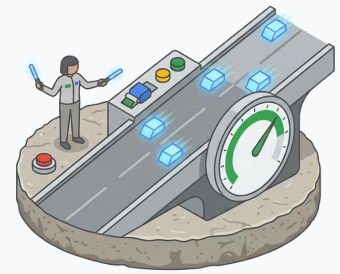
按 延迟预算 与 风险等级 动态路由控制成本

明确选型边界：分级路由把控总体成本（预估）

小米典型业务场景	推荐防护组合方案	延迟预算（实测/预估）	架构权衡与选型说明
终端实时语音/对话助手	仅第一层 Model Armor + 异步抽检	0.7 – 0.9 s（实测文本）	延迟敏感，同步链路不串行叠加完整大模型复核
海外应用商店与社区评论	Model Armor 全量 + POSSIBLE 复核	1.3 s 基线 / 2.5 s 复核	约 85% 常规图文由首层处理，省约 70% 成本（预估）
广告主与促销落地页准入	三段式流水线 + 双层全量审核	3.0 – 5.0 s（异步准入）	准入工单对延迟不敏感，优先保障黑产伪装高召回
静态固定黑名单高频过滤	本地前缀树过滤 + Model Armor 兜底	< 50 ms（本地缓存命中）	高频固定词无需每次调云端 API，本地前置更经济

低延迟车道

实时对话仅走首层



精细化成本

按置信度分流推理

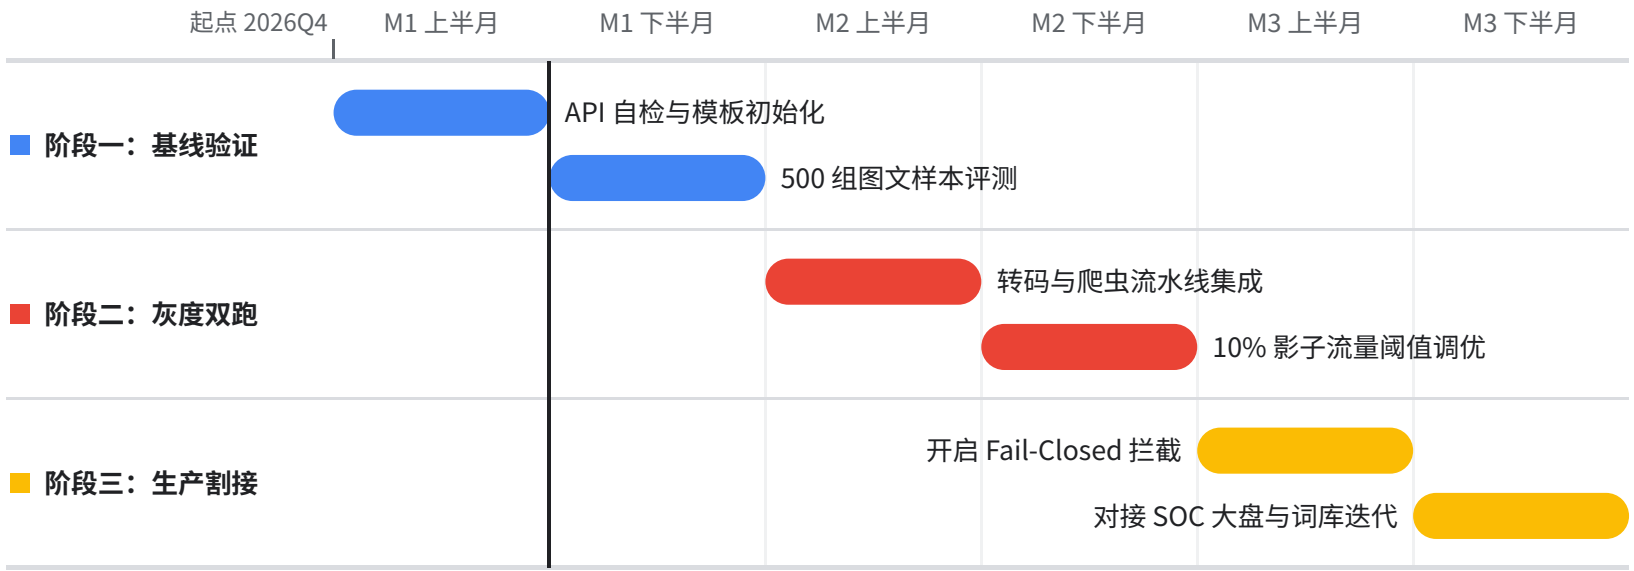


诚实选型权衡 — 仅拦截固定违禁词且要求 50 ms 内返回的边缘网关，本地正则更经济。

IMPLEMENTATION ROADMAP

分三阶段推进 PoC 验证 与全量生产割接

设定量化准出指标，90 天完成双层安全上线



条宽 = 跨度　竖线 = PoC 启动里程碑

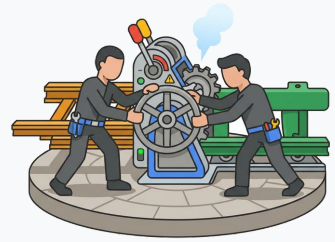
Day 1–30 准出

完成 500 组样本基线评测



Day 31–90 准出

影子流量校准后切生产拦截



开箱即用资产 — 已备好含一键初始化、OCR 解析与 Gemini 4 复核的完整 Jupyter Notebook 供复现。

SECTION 02 · GEMINI 4.0 (ARGON) FRONTIER MODEL

Gemini 4.0 (Argon) 正式 GA：面向深度推理与复杂工程的前沿模型

10 月 13 日 GA，12 个月生命周期与 99.5% SLA



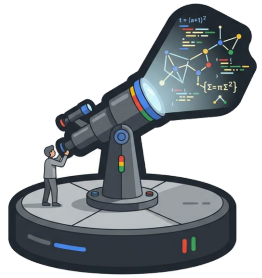
1M

行业首创 1M Input + 1M Output Tokens 双向百万级上下文与连续长推演窗口

为什么命名为 Gemini 4.0 Argon?

- 开启 Gemini 4 模型尺寸全新命名体系（以 **Argon** 首发领航）
- 较前代 3.1 Pro 在前沿编程与网络安全基准上实现 **最高 +25 个百分点** 的跨越式提升
- 定位高复杂度、多步骤任务，与高吞吐 **Gemini 3.8 Flash** 形成高低协同

三大核心领跑域：工程、知识工作与安全防御



- **软件工程**：DeepSWE v1.1 达 **77.9%**
- **知识工作**：Vals Index 排名 **#1 (68.9%)**
- **网络安全**：自主发现、验证并修补高危漏洞

Long-Term GA

生产承诺与全渠道同步上线



- **Long-Term GA**：12 个月支持与 **99.5% SLA**
- **Day 1 可用**：Global、US/EU 多区域端点
- 同步登陆 **Gemini Enterprise** 与 **Antigravity**

产品定位：gemini-4-argon 是目前 Google 最强大的前沿推理模型，专为需要长时思考（Sustained Thinking）与多步执行的复杂任务打造。

GEMINI 4.0 ARGON · CORE CAPABILITIES

四大技术支柱：1M 超长连续解码、自主软件工程与原生全模态

单次推理完成大型代码库重构与漏洞修复

01 · 行业首创 1M Output 长解码

输出上限从 64K 跃升至 1,000,000 Tokens

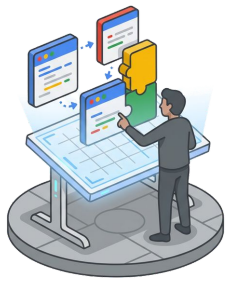
- 支持数万行级完整模块代码一次性生成与长链路数学科学推演
- **GraphWalks (1M Context)** 得分高达 **84.2%**（领先同类前沿模型 +12.4 pts）
- 原生集成至 **AlphaEvolve**，驱动复杂算法设计与科学发现



02 · 端到端多文件 Agentic Coding

DeepSWE v1.1 实测 77.9% 排名第一

- 专为跨多文件真实代码仓库重构、终端命令执行与自动化测试打造
- **AutomationBench** 端到端业务流执行得分 **51.3%**（领先 +8.8 pts）
- 作为核心推理引擎全面驱动 **Antigravity 2.0**、CLI 与 IDE 插件



03 · 自主网络安全防御与全模态

CWE-Bench v1 漏洞修复率提升至 73.23%

- 裸模型在 CWE-Bench 达 **68.0%**，结合 **CodeMender** 自动验证修补升至 **73.23%**
- **原生全模态统一推理**：跨文本、代码、音频、PDF 与视频直接推理，免除外挂视觉切分流水线



架构师视角：1M 输入解决“读得全”，**1M 输出解决“写得完与想得深”**，彻底消除长周期 Agent 任务的中途截断与上下文丢失。

FRONTIER BENCHMARKS & TOKEN ECONOMICS

权威基准与商业经济学：六大评测全面领跑，单任务 TCO 仅 $1.99

首发 5 折与 95% 缓存折扣，122 TPS 吞吐



权威评测基准（截至 2026-09-30）	评测领域	Gemini 4.0 Argon	主流前沿参照 A	主流前沿参照 B	领先幅度
DeepSWE v1.1	长周期软件工程	77.9%	74.2%	74.1%	+3.7 pts (#1)
Vals Index（GDP 加权）	企业编码/金融/法务	68.9%	67.0%	65.8%	+1.9 pts (#1)
GraphWalks (1M Context)	百万上下文深度推理	84.2%	66.8%	71.8%	+12.4 pts (#1)
Vals Finance Agent v2	多步金融研究分析	65.4%	58.6%	58.9%	+6.5 pts (#1)
AutomationBench	端到端业务流自动化	51.3%	42.5%	41.4%	+8.8 pts (#1)
CWE-Bench v1 (+CodeMender)	自主漏洞发现与修复	73.2%（裸模 68%）	—	—	行业领先水平

首发期特惠定价与隐式缓存

输入 **$2 / 1M**，输出 **$10 / 1M**

- 隐式缓存低至 **$0.10 / 1M**（**95% 折扣**）



单任务综合成本降低 66%

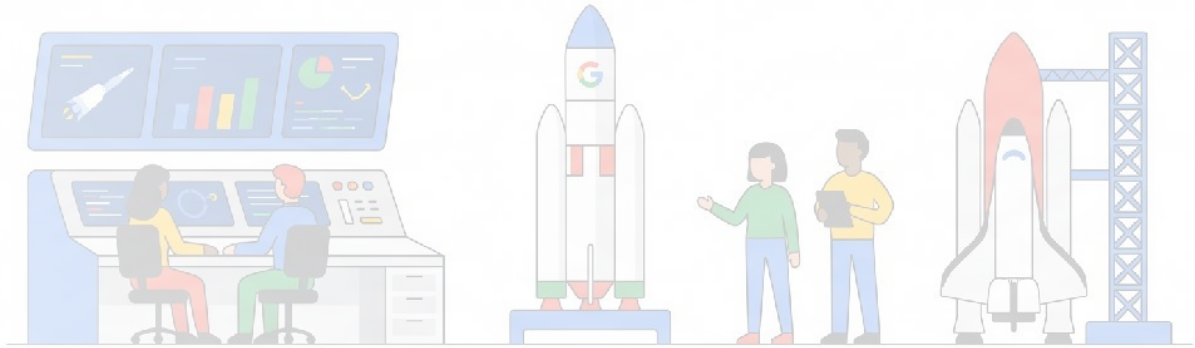
- 单任务成本约 **$1.99**（Artificial Analysis）
- Token 消耗减半，输出 **122 TPS**



成本与效率洞察：得益于更高的单次推理准确率（AA-Omniscience 幻觉率仅 15%）与 95% 隐式缓存折扣，真实 Agent 任务总成本仅为同类方案的 **1/3**。

Antigravity 2.0：从单一代码补全插件演进为独立多智能体指挥中心

Agent Manager 独立成桌面应用，多智能体并行



LEGACY IDE COPILOT

传统 IDE 辅助编码（1.0 模式）

局限于单一编辑器内的对话补全

串行交互，开发者需盯屏等待

缺少前置计划，易偏离设计意图

长任务上下文易被日志撑满

VS

ANTIGRAVITY 2.0 MISSION...

Antigravity 2.0 独立指挥中心 (Agent-First)

跨平台桌面应用 + CLI + SDK

先审 /plan 计划，再后台执行

Subagents 并行推进多条工作流

定时任务与原生语音指令

Mission Control 独立桌面端

再绑定单一代码编辑器，面向所有构建者提供全局多智能体调度台

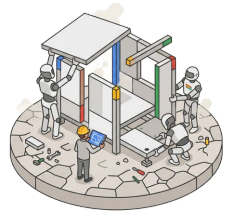
- 支持同时监控本地与云端多个异步 Agent 任务流



“施工监理”人机协同范式

Agent 是总包施工方，开发者是现场监理

- 人工把控“审批架构计划”与“验收代码 Diff”两个关键决策点



范式升级：让工程师从“逐行盯屏结对编程”解放出来，以架构监理身份同时并行管理多个由 **Gemini 4.0 Argon** 驱动的自主研发工作流。

ANTIGRAVITY 2.0 · ORCHESTRATION WORKFLOW

四大核心引擎：规划、并行、定时与语音

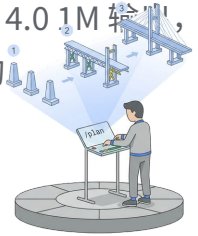
从被动问答走向全天候主动式工程智能体

1. 语音/指令输入	2. 架构与测试规划	3. Subagents 并行执行	4. Cron 自动化与交付
Voice 或 /plan 发起任务	生成实现方案与验证矩阵	主从分治 + 独立分支沙箱	定时唤醒巡检 + Diff 审批

Mission Control 与 /plan 规划

先规划、后执行、自动跑通测试

- 输入 /plan 触发深度推理模式，输出完整实施蓝图与测试验证计划
- 内置 /browser 自动化浏览器验证与可视化 Artifact 报告审阅
- 结合 Gemini 4.0 1M 输入，单次规划可覆盖大型跨模块重构



Subagents 主从多智能体并行

主 Agent 控全局，子 Agent 专精深潜

- 单条提示词动态派生多个 research 或专项编码 Subagents 并行作业
- 支持 branch / share 隔离工作区，避免多智能体并发改写冲突
- 子智能体完成后通过响应式消息唤醒主会话，零轮询开销



Scheduled Tasks 与原生语音驱动

Cron 定时自动驾驶 + 麦克风自然口述

- **Scheduled Tasks**：配置 Cron 表达式，Agent 按时唤醒执行晨间 PR 汇总或云端健康巡检
- **Voice 语音指令**：直接通过麦克风口述复杂需求，由 Gemini 音频理解直转工程任务



端到端工程提效：通过 /plan 锁定架构方向、Subagents 并发缩短长尾耗时、Scheduled Tasks 实现无人值守夜间构建与巡检。

ANTIGRAVITY ECOSYSTEM & HARDWARE INTEGRATION

全栈工具链与生态集成：四端协同、多模型路由与端侧硬件开发

桌面、CLI、IDE 与 SDK 全覆盖，支持端侧部署



Antigravity 产品形态	核心定位与适用人群	模型选择与集成特性
Antigravity 2.0 Desktop	跨平台桌面指挥中心	编排多 Agent、定时任务与 Diff 审阅
Antigravity CLI (agy)	终端命令行智能体	支持 /model 按轮次切换模型
IDE Extensions	VS Code、JetBrains、Zed 等	通过 ACP 协议嵌入既有编辑器
Antigravity SDK	企业自建 Agent 框架	支持私有化部署与 LiteRT 离线运行

一键集成 Android 与 Google 生态

- 接入 Android、Firebase、Chrome
- 预置 Google Cloud MCP Servers



硬件工程与端侧 LiteRT 协同

- 支持 PCB 辅助设计与旧代码现代化
- SDK 支持 **LiteRT** 端侧离线运行 Gemma 4



多模型自由路由 + Google Cloud 企业级安全治理

- **多模型**：Gemini 4.0 Argon、3.8 Flash 及第三方与开源模型
- **企业安全**：沙箱隔离、访问控制、漏洞扫描与数据零训练承诺

生态协同亮点：云端由 **Gemini 4.0 Argon** 驱动重度研发与跨仓重构，端侧通过 **Antigravity SDK + LiteRT** 部署离线轻量化模型。